OBLIGATORIO DE INTELIGENCIA ARTIFICIAL

Prediccion de cancelaciones hoteleras

Diseno, implementacion y evaluacion de un proyecto integrador de Machine Learning

Sabine Theiss | Jorge Avellanal | Mateo Mendiondo
Electiva Inteligencia Artificial - Licenciatura en Informatica, UDE
3 de noviembre de 2026

Resumen ejecutivo

Se entreno un modelo para ordenar reservas por riesgo de cancelacion, usando variables disponibles al momento de reservar y una particion temporal con maduracion del resultado. En validacion temporal anidada, Gradient Boosting obtuvo Average Precision (AP) media de 0,538 (+/- 0,057), por encima del baseline aleatorio (AP 0,301). La evaluacion final, ejecutada una sola vez con umbral 0,50 bajo el supuesto acordado de costos relativos FP=FN=1, obtuvo AP 0,642, ROC-AUC 0,776, precision 0,704 y recall 0,345.

La lectura del test requiere cautela: una version previa del trabajo inspecciono etiquetas de otro holdout temporal y hay filas compartidas, por lo que este test no es completamente ciego. No debe usarse para escoger modelos, variables o umbral. No se recomienda desplegar el score ni tomar decisiones de sobreventa sin datos operativos reales, validacion reciente por hotel y un piloto supervisado.

1. Problema y criterio de decision

El target es is_canceled (1 = cancelada). El score podria apoyar al area de reservas/revenue management para priorizar seguimiento y planificar capacidad. Un falso negativo omite una cancelacion y podria dejar una habitacion vacia; un falso positivo puede generar una intervencion innecesaria o una sobreventa riesgosa. No hay costos monetarios, capacidad ni eficacia de intervenciones disponibles. El equipo acordo para la evaluacion un escenario academico de costos relativos iguales (FP=FN=1), cuyo umbral teorico es 0,50; no representa un costo de negocio validado.

AP es la metrica tecnica principal por el desbalance y el interes en ordenar riesgo. Se complementa con precision/recall/F1, ROC-AUC, calibracion y escenarios top-k de capacidad. Accuracy no se usa como criterio principal.

2. Datos, particion y calidad

Se uso Hotel Booking Demand, con 119.390 reservas y 32 columnas (31 predictores y el target), correspondientes a dos hoteles de Portugal y llegadas entre julio de 2015 y agosto de 2017. La copia publica de Kaggle tiene licencia CC BY 4.0. Es un conjunto observacional e historico; no garantiza generalizacion a otros hoteles o periodos.

Conjunto	Reservas	Periodo de fecha estimada de reserva	Uso
Train maduro	79.870	24/06/2013 - 11/01/2017	EDA, validacion y ajuste
Test temporal	23.989	12/01/2017 - 31/08/2017	Evaluacion final unica
Purgado	15.531	Reservas anteriores al corte con llegada posterior	Resultado aun no maduro al corte

Como no existe la fecha real de creacion, se aproxima con arrival_date - lead_time. Se ordeno antes de modelar y se aplico tambien una regla de madurez (llegada anterior al corte) para el train.

Calidad en train: 23.172 duplicados exactos (29,0%); 94,29% de company y 13,67% de agent faltantes; country 0,51% y children solo 4 filas. Los faltantes variaron por resultado: company 97,49% en canceladas vs. 92,48% en no canceladas; agent 7,83% vs. 16,97%; country 0,19% vs. 0,69%; children 0,014% vs. 0%. Estas diferencias son descriptivas. Se observaron ADR de hasta 5.400, adultos hasta 55, lead_time hasta 737 días y 580 reservas de cero noches. Se mantuvieron filas con faltantes, con imputación dentro del pipeline. La variante deduplicada cambió la tasa positiva de 36,12% a 25,04%, por lo que se reportó como sensibilidad y no como reemplazo del conjunto principal.

El notebook contiene seis visualizaciones con conclusiones: balance de clases (36,1% canceladas en train); tasas distintas por hotel (City 41,3%, Resort 26,2%); variacion mensual (27,2%-39,6%); mayor cancelacion con anticipacion alta (77,8% para mas de 365 dias, n=1.801); asociacion descriptiva de deposit_type (99,2% Non Refund); y distribucion de ADR por resultado. Son asociaciones, no efectos causales.

3. Fuga, variables y validacion

Se auditaron las columnas por disponibilidad al reservar y riesgo de proxy. Se excluyeron reservation_status y reservation_status_date del modelo valido; tambien booking_changes y assigned_room_type, y variables cuya disponibilidad en ese momento no se pudo confirmar (deposit_type, ADR, dias en lista de espera, espacios de estacionamiento y solicitudes especiales). El preprocesamiento se ajusta dentro de pipelines y folds.

Se derivaron 10 predictores sin estado usados por el modelo: duracion y composicion de la estadia, presencia de ninos, calendario (mes, dia, fin de semana y codificacion ciclica), tramo de anticipacion e historial previo de cancelaciones. Las categoricas se codifican dentro del pipeline. Se compararon familias de modelos en cinco folds temporales purgados; la busqueda anidada uso tres folds internos.

Modelo (validacion temporal)	AP media	Desv. estandar
Baseline trivial	0,3014	0,0466
Regresion logistica	0,5112	0,0343
Random Forest	0,5266	0,0376
Gradient Boosting	0,5220	0,0577
SVM RBF aproximado (Nystrom)	0,5117	0,0551

La busqueda anidada selecciono Gradient Boosting como candidato principal (AP externa 0,5380 +/- 0,0567) y Random Forest como referencia (0,5185 +/- 0,0287). Con entrenamiento deduplicado y las mismas ventanas, sus AP fueron 0,4969 +/- 0,0306 y 0,5099 +/- 0,0365, respectivamente. Configuracion final del candidato: Gradient Boosting, 100 estimadores, learning_rate=0,1 y max_depth=2; despues se calibro con sigmoid usando solo train.

4. Experimentos y calibracion

La fuga deliberada que agrega reservation_status y reservation_status_date elevo la AP media de 0,5393 a 1,0000 (+0,4607) en los mismos folds. Esas columnas contienen informacion posterior al resultado y no son aceptables como predictores.

Ablation Gradient Boosting	AP media	Cambio vs. conjunto completo
Completo	0,5393	-
Sin anticipacion	0,5392	-0,0000
Sin calendario	0,5381	-0,0011
Sin composicion/estadia	0,5373	-0,0020
Sin historial	0,5366	-0,0027

La seleccion SelectFromModel con ExtraTrees se ajusto dentro de cada fold: AP media aproximada 0,521 y entre 88 y 116 variables transformadas retenidas. La calibracion temporal fuera de muestra en 39.841 reservas dio Brier 0,2160 y log loss 0,6717. Los escenarios de costos relativos se muestran como sensibilidad; para FP=FN=1, el umbral 0,50 produjo 41,7 alertas por 1.000 y muchos falsos negativos en validacion, lo que advierte que el umbral depende del uso y la calibracion.

5. Evaluacion final del test

El test temporal de 23.989 reservas se abrio una sola vez tras acordar FP=FN=1 y umbral 0,50. Habia 7.561 cancelaciones (31,5%). La matriz de confusion (filas real, columnas predicho) fue:

	Predijo no cancela	Predijo cancela
Real no cancela	15.330	1.098
Real cancela	4.953	2.608

Metrica	Estimacion	IC bootstrap 95%
Average Precision	0,6424	[0,6319; 0,6534]
ROC-AUC	0,7756	[0,7696; 0,7819]
Precision (umbral 0,50)	0,7037	[0,6881; 0,7185]
Recall (umbral 0,50)	0,3449	[0,3346; 0,3557]
F1 (umbral 0,50)	0,4629	[0,4521; 0,4744]
Brier / log loss	0,1708 / 0,5157	-

Bootstrap percentil con 1.000 replicas. Como referencia de ranking, alertar el 5%, 10% y 20% de mayor riesgo dio precision@k de 0,874 / 0,796 / 0,637 y recall@k de 0,139 / 0,252 / 0,404, frente a una prevalencia aleatoria de 0,315. Son escenarios de capacidad, no una recomendacion de sobreventa. La precision-recall y el resto de salidas quedan en el notebook.

6. Interpretacion, riesgos y recomendacion

La importancia por permutacion temporal ubico country (caida AP media 0,126), lead_time (0,086), market_segment (0,047), customer_type (0,029) y agent (0,020) entre las senales mas relevantes. La dependencia parcial examino lead_time y total_nights. Las diferencias entre subgrupos se reportan descriptivamente; no prueban causalidad ni equidad estable.

- La particion test no es completamente ciega: existe una inspeccion previa de etiquetas y filas compartidas. Interpretar su AP con cautela y no reajustar el modelo a partir de ella.
- La fecha de reserva es estimada; la copia corresponde solo a dos hoteles y puede haber cambio temporal, deriva, categorias nuevas y distinta calibracion por hotel o segmento.
- Con umbral 0,50 el recall es 0,345: el modelo deja sin detectar una proporcion importante de cancelaciones. La tasa de alertas varia entre validacion y test.
- No usar el modelo directamente para overbooking. Antes de un piloto se requieren costos reales, datos recientes por hotel, umbral acordado con operaciones, supervision humana y monitoreo de datos, AP, precision/recall, calibracion y deriva.

7. Artefactos, uso de IA y fuentes

Se guardo el pipeline calibrado en hotel_cancellation_pipeline.joblib y se genero predict.py para preparar una entrada CSV y producir probabilidad y clasificacion. El notebook conserva los outputs de la ejecucion; por seguridad metodologica la celda del test queda desactivada para futuras ejecuciones y no debe abrirse de nuevo.

Uso de IA: ChatGPT apoyó la ideación del problema y el EDA, la propuesta de variables, la auditoría de fuga y borradores del código y del informe. Copilot en VS Code apoyó la implementación y revisión de cambios. El equipo verificó las propuestas mediante ejecución reproducible y revisión manual; excluyó variables posteriores al resultado y aquellas cuya disponibilidad al reservar no estaba confirmada.

Antonio, N., Almeida, A., & Nunes, L. (2019). Hotel booking demand datasets. Data in Brief, 22, 41-49. https://doi.org/10.1016/j.dib.2018.11.126

Mostipak, J. Hotel Booking Demand (Kaggle), version derivada del conjunto original. https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand/data. Licencia reportada: CC BY 4.0.

OpenAI. ChatGPT (2026), herramienta de asistencia para ideacion, codigo y redaccion; las decisiones, ejecuciones y validaciones fueron revisadas por el equipo.